

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных»
Тема: Применение метода главных компонент для визуализации выборки
seeds

Выполнил:
Студент 4 курса
Группы ИИ-26(2)
Семёнов А.В.
Проверил:
Никитин

Брест 2026

Метод главных компонент для выборки seeds

1 Условие работы и подготовка данных

Цель работы — применить метод главных компонент PCA для визуализации многомерных данных. По варианту 1 используется архив seeds.zip; последняя колонка содержит класс. Требуется независимо получить проекции на первые две и три компоненты через `numpy.linalg.eig` и `sklearn.decomposition.PCA`, визуализировать классы и оценить потери по собственным значениям.

В архиве находится seeds_dataset.txt: 210 строк и 8 числовых колонок. Первые семь колонок образуют матрицу признаков X размера 210×7 ; восьмая отделена в вектор меток. Представлены классы 1, 2 и 3, по 70 объектов каждого. Метки используются только для цветовых маркеров и не участвуют в центрировании, вычислении ковариации и PCA.

Файл читается через `pandas.read_csv` с разделителем из одного или нескольких пробельных символов. Повторные табуляции считаются разделителями, а не пропусками. В исходной выборке нет NaN и бесконечных значений. Для явно заданного пропуска в признаке программа предусматривает замену медианой этого столбца; полностью пустой столбец и пропуск класса отклоняются.

Характеристики семи входных колонок

Признак	Среднее	Выборочное s	Минимум	Максимум
X1	14,84752	2,90970	10,5900	21,1800
X2	14,55929	1,30596	12,4100	17,2500
X3	0,87100	0,02363	0,8081	0,9183
X4	5,62853	0,44306	4,8990	6,6750
X5	3,25860	0,37771	2,6300	4,0330
X6	3,70020	1,50356	0,7651	8,4560
X7	5,40807	0,49148	4,5190	6,5500

Стандартизация

Основной эксперимент выполнен после стандартизации: масштабы исходных столбцов различаются. Например, стандартные отклонения X1 и X3 равны 2,90970 и 0,02363. Деление на стандартное отклонение позволяет учитывать каждый признак в одинаковом масштабе.

$$z_{ij} = (x_{ij} - \mu_j)/s_j; \quad \mu_j = (1/n)\sum_i x_{ij}$$
$$s_j^2 = (1/(n - 1))\sum_i (x_{ij} - \mu_j)^2; \quad n = 210$$

Используется выборочное стандартное отклонение, `ddof = 1`. После преобразования средние равны нулю с точностью округления, дисперсии равны единице, а суммарная дисперсия семи признаков равна 7. Оба способа PCA получают одну и ту же подготовленную матрицу Z .

2 Два независимых способа вычисления PCA

Ручной способ через собственные значения

По центрированной матрице Z строится симметричная ковариационная матрица S размера 7×7 . Функция `numpy.linalg.eig` возвращает её собственные значения и собственные векторы. Значения сортируются по убыванию; соответствующие столбцы матрицы собственных векторов переставляются в том же порядке.

$$S = Z^T Z / (n - 1); \quad S v_j = \lambda_j v_j; \quad \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_7$$

$$V_k = [v_1 \dots v_k]; \quad T_k = Z V_k; \quad k \in \{2, 3\}$$

Матрица T_2 имеет размер 210×2 , T_3 — 210×3 . Их строки задают координаты объектов на графиках. Проверяются отсутствие значимой мнимой части, неотрицательность спектра с учётом округления и ортонормированность базиса. Отбрасывание компонент с малыми собственными значениями уменьшает размерность с наименьшей квадратичной ошибкой в выбранном масштабе.

Библиотечный способ

Для каждой размерности отдельно создаётся `sklearn.decomposition.PCA(n_components=k, svd_solver="full", whiten=False)` и вызывается `fit_transform(Z)`. Библиотечное решение использует полное сингулярное разложение подготовленной матрицы. Собственные значения, векторы или координаты из ручного решения в PCA не передаются. Whitening отключён, чтобы сохранить обычный масштаб главных компонент.

Знаки и сравнение решений

Векторы v и $-v$ задают одну ось, поэтому два правильных решения могут различаться знаками координат. Для каждой компоненты в каждом решении независимо выбирается знак, при котором наибольший по модулю коэффициент положителен. После этого сравниваются координаты. Дополнительно сравниваются собственные значения и проекторы $V_k V_k^T$, не зависящие от знаков векторов.

Расчёт потерь

$$D_k = \sum_{j=k+1}^7 \lambda_j; \quad L_k = D_k / (\sum_{j=1}^7 \lambda_j) \cdot 100\%$$

$$R_k = 100\% - L_k; \quad Z_k = T_k V_k^T$$

$$SSE_k = \|Z - Z_k\|^2 = (n - 1) D_k; \quad MSE_k = SSE_k / (n \cdot 7)$$

D_k — отброшенная дисперсия, L_k — доля потерянной дисперсии, R_k — сохранённая доля. SSE суммирует квадраты отклонений всех 1470 элементов матрицы; MSE усредняет их. Потери относятся к стандартизованным признакам, а не к проценту неверных классов и не ко всей возможной информации о данных.

3 Собственные значения и численные результаты

Собственные значения вычислены по полной стандартизированной выборке. Все семь значений положительны. Сумма равна 7 с точностью вычислений. Доля отдельной компоненты равна $\lambda_j/7$; накопленная доля определяется суммой первых компонент.

Компонента	λ	Доля дисперсии, %	Накопленная доля, %
PC1	5,031201186	71,874303	71,874303
PC2	1,197572847	17,108184	88,982486
PC3	0,678003439	9,685763	98,668250
PC4	0,068364477	0,976635	99,644885
PC5	0,018713609	0,267337	99,912222
PC6	0,005332046	0,076172	99,988394
PC7	0,000812397	0,011606	100,000000

Сравнение сохранённой дисперсии и потерь

k	Способ	Сохранено, %	Потеряно, %
2	NumPy eig	88,982486	11,017514
2	sklearn PCA	88,982486	11,017514
3	NumPy eig	98,668250	1,331750
3	sklearn PCA	98,668250	1,331750

k	D_k	SSE_k	MSE_k
2	0,771225967	161,186227	0,109650495
3	0,093222528	19,483508	0,013254087

При двух компонентах сохраняется 88,982486% дисперсии, при трёх — 98,668250%. Третья компонента добавляет 9,685763 процентного пункта и уменьшает потерю с 11,017514% до 1,331750%. Для сохранения не менее 95% стандартизированной дисперсии достаточно трёх компонент, а двух недостаточно.

Разность между собственными значениями ручного и библиотечного способов не превышает $4,45 \cdot 10^{-15}$. Максимальное расхождение координат после выбора знаков — $3,13 \cdot 10^{-15}$; элементов проекторов — $3,34 \cdot 10^{-16}$. Расхождения имеют порядок машинного округления. Непосредственная ошибка реконструкции совпала с $(n - 1)D_k$ и с ошибкой библиотечного решения.

4 Визуализация первых главных компонент




Рисунок 1 — Проекция на первые две компоненты двумя способами

На плоскости PC1–PC2 видны три преимущественные области: класс 2 расположен справа, класс 3 — слева, класс 1 — между ними и ниже по PC2. В пограничных областях точки разных классов перемешиваются. PCA не использует метки и не оптимизирует разделение классов, поэтому такое перекрытие допустимо.




Рисунок 2 — Проекция на первые три компоненты двумя способами

PC3 показывает дополнительные различия объектов по третьему направлению и уменьшает потери почти до 1,33%. Для сопоставления заданы одинаковые пределы осей, цветовые маркеры и ракурс. Правая и левая проекции совпадают; различие метода вычисления не меняет геометрию данных. Пространственный график можно вращать мышью при обычном запуске программы.

5 Интерпретация спектра и влияние масштаба




Рисунок 3 — Спектр и накопленная объяснённая дисперсия

PC1 содержит 71,874303% стандартизованной дисперсии; PC2 — 17,108184%; PC3 — 9,685763%. После третьей компоненты спектр резко уменьшается: все оставшиеся компоненты вместе дают 1,331750%. Поэтому переход от семи признаков к трём позволяет сохранить основную геометрию выборки в выбранной метрике.

Коэффициенты первых трёх компонент

Признак	PC1	PC2	PC3
X1	0,4445	0,0266	0,0259
X2	0,4416	0,0840	-0,0598
X3	0,2770	-0,5292	0,6297
X4	0,4236	0,2060	-0,2119
X5	0,4328	-0,1167	0,2165
X6	-0,1187	0,7169	0,6795
X7	0,3872	0,3772	-0,2139

PC1 в основном объединяет признаки X1, X2, X4, X5 и X7 с положительными коэффициентами. Во второй компоненте наиболее заметны X6 и X3 с противоположными знаками, в третьей — X6 и X3 с одинаковыми знаками. Приведены коэффициенты нормированных собственных векторов; их знак выбран по описанному правилу.

Дополнительный расчёт без стандартизации

Подготовка	Потери при k = 2, %	Потери при k = 3, %
Центрирование и деление на s	11,017514	1,331750
Только центрирование	0,698235	0,132444

Без деления на s две компоненты сохраняют уже 99,301765% исходной суммарной дисперсии. Это не означает, что этот вариант лучше сохраняет все признаки: в исходной шкале крупные дисперсии имеют больший вес. Проценты относятся к разным метрикам. Основной вывод о достаточности трёх компонент относится к стандартизованным данным; программа также позволяет воспроизвести вариант с одним центрированием.

Проверки реализации

Автоматические проверки подтвердили размер 210×7 , три класса по 70 объектов и отсутствие пропусков. Проверены нулевые средние и единичные выборочные дисперсии после стандартизации, равенство $Sv_j = \lambda_j v_j$, ортонормированность собственных векторов и восстановление полной матрицы при сохранении всех семи компонент.

Для $k = 2$ и $k = 3$ проверены совпадение ручного и библиотечного решений, равенство ошибки реконструкции сумме отброшенных собственных значений с множителем $n - 1$, загрузка TXT и ZIP и замена искусственно добавленного NaN медианой. Эти проверки прошли как со стандартизацией, так и при одном центрировании.

6 Выводы

Метод PCA реализован двумя независимыми способами. Результаты `numpy.linalg.eig` и `sklearn.decomposition.PCA` совпали с точностью до машинного округления, что подтверждено сравнением спектров, проекторов, координат и реконструкций.

Для стандартизованной выборки `seeds` проекция $7 \rightarrow 2$ сохраняет 88,98% дисперсии и теряет 11,02%; проекция $7 \rightarrow 3$ сохраняет 98,67% и теряет 1,33%. Двумерная проекция удобна для обзорного изображения, трёхмерная заметно точнее передаёт геометрию и достигает выбранного ориентира 95%.

На графиках проявляется структура трёх классов, но частичное перекрытие сохраняется. Доля сохранённой дисперсии не является точностью классификации. Выбор масштаба признаков существенно влияет на спектр и численные потери, поэтому подготовка данных должна быть указана вместе с результатом PCA.