

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных»
Тема: Предобучение нейронных сетей с использованием автоэнкодеров

Выполнил:
Студент 4 курса
Группы ИИ-26(2)
Семёнов А.В.
Проверил:
Никитин С.К.

Брест 2026

Послойное предобучение глубоких нейронных сетей

1 Условие работы и исходные данные

Цель работы — реализовать автоэнкодерное предобучение глубокой нейронной сети и сравнить качество классификации с обучением той же архитектуры без предобучения. По варианту 1 используется Credit Approval с целевой переменной «+ / –». Согласно пункту 4 задания эксперимент повторяется на WDBC — выборке варианта 1 из лабораторной работы №2.

Для каждой выборки выполнены три парных запуска с разными начальными весами. Основные показатели — F1 положительного класса и матрица ошибок; дополнительно рассчитаны accuracy, precision, recall, macro-F1 и ROC-AUC. В выполненных экспериментах предобучение не улучшило средний F1: для Credit Approval он снизился, для WDBC остался тем же.

Выборка	Объекты	Исходные признаки	Классы 0 / 1	Численность 0 / 1
Credit Approval	690	15	– / +	383 / 307
WDBC	569	30	В / М	357 / 212

Credit Approval

Исходный файл `crx.data` получен из UCI Machine Learning Repository. Он содержит 15 входных столбцов A1–A15 и класс A16. Названия и значения атрибутов обезличены, поэтому им не приписывается предметный смысл. Положительному классу «+» присвоено значение 1, классу «–» — 0.

Числовые столбцы: A2, A3, A8, A11, A14 и A15. Остальные девять — категориальные. Символ «?» обозначает пропуск. Всего обнаружено 67 пропущенных значений в 37 строках. Числовые пропуски заменяются медианой, категориальные — наиболее частым значением, вычисленными по обучающей части.

Числовые столбцы стандартизуются с помощью `StandardScaler`; категориальные преобразуются `OneHotEncoder` без удаления первой категории. Неизвестная категория при преобразовании отложенных данных кодируется нулевым блоком. После обучения преобразователя на `train` получается 46 входных координат: 6 числовых и 40 категориальных индикаторов.

WDBC из лабораторной работы 2

Выборка загружается через `sklearn.datasets.load_breast_cancer`. Матрица содержит 30 числовых признаков; идентификатор в неё не входит. Диагноз используется только как целевая переменная. Здесь класс М перекодирован в 1, класс В — в 0, чтобы `recall` характеризовал выявление положительного класса М. Пропусков нет; стандартизатор обучается только на `train`.

2 Архитектура и алгоритм предобучения

Использована полносвязная сеть $d-64-32-16-8-1$, где $d = 46$ для Credit Approval и $d = 30$ для WDBC. Она содержит четыре скрытых слоя и выходной слой, то есть пять обучаемых линейных преобразований. Вход не считается обучаемым слоем. Требование методички «более 3 слоёв» выполнено.

$$x \rightarrow \text{Linear}(d, 64) \rightarrow \text{ReLU} \rightarrow \text{Linear}(64, 32) \rightarrow \text{ReLU} \\ \rightarrow \text{Linear}(32, 16) \rightarrow \text{ReLU} \rightarrow \text{Linear}(16, 8) \rightarrow \text{ReLU} \rightarrow \text{Linear}(8, 1)$$

Последний слой выдаёт логит a . Вероятность положительного класса равна $\text{sigmoid}(a)$. Во время supervised-обучения применяется BCEWithLogitsLoss, объединяющая сигмоиду и бинарную кросс-энтропию численно устойчивым способом. Порог классификации заранее зафиксирован на 0,5 и не подбирается по тесту.

Послойный алгоритм из лекции

1. Первый скрытый слой становится кодировщиком автоэнкодера $d-64-d$. Кодировщик имеет ReLU, декодировщик линеен. Сеть обучается восстанавливать подготовленные входы train по MSE без использования меток классов.

2. После 100 эпох веса и смещения кодировщика переносятся в первый скрытый слой классификатора. Декодировщик отбрасывается. Выходы кодировщика вычисляются без градиентов и становятся обучающими входами следующего автоэнкодера.

3. Аналогично обучаются автоэнкодеры $64-32-64$, $32-16-32$ и $16-8-16$. При обучении очередного слоя ранее обученные слои фиксированы. Переносится именно кодирующая половина каждой сети, включая смещения.

4. После предобучения четырёх скрытых слоёв выходной слой классификатора обучается с учителем при фиксированном кодировщике. Затем все слои размораживаются, и вся сеть совместно дообучается обратным распространением ошибки. Последовательность соответствует слайду 13 приложенной лекции.

$$h_l = \text{ReLU}(W_l h_{l-1} + b_l); \quad h_0 = x \\ \hat{h}_{l-1} = D_l h_l + c_l; \quad \text{MSE}_l = \sum_i \sum_j (h_{ij} - \hat{h}_{ij})^2 / (n \cdot d_{l-1})$$

Для слоя l восстанавливается его собственный вход h_{l-1} , а не исходная метка класса и не всегда исходный вектор x . Линейный декодировщик допускает восстановление отрицательных стандартизованных координат. Первое скрытое пространство шире входа; это допустимый избыточный автоэнкодер. Дальнейшие слои постепенно уменьшают размерность до восьми.

3 Схема сравнения и метрики

Каждая выборка один раз стратифицированно делится в пропорции 60/20/20 с `random_state=42`. Пропорции классов сохраняются с округлением до целого числа объектов. Разбиение общее для обоих режимов и всех трёх инициализаций. Индексы частей сохраняются в `results.json`.

Выборка	Часть	Объекты	Класс 0	Класс 1
Credit Approval	Обучение	414	230	184
Credit Approval	Валидация	138	76	62
Credit Approval	Тест	138	77	61
WDBC	Обучение	341	214	127
WDBC	Валидация	114	71	43
WDBC	Тест	114	72	42

Медианы, моды, средние, стандартные отклонения и словари категорий оцениваются только по `train`. Предобучение также получает исключительно `train`, без меток. `Validation` используется для выбора эпохи `supervised`-дообучения. `Test` используется после выбора весов для итоговых метрик; результаты теста не определяют параметры обучения.

Параметр	Значение
Инициализации	42, 43, 44; одинаковые начальные веса внутри пары
Оптимизатор	Adam; $lr = 0,001$; $\beta_1 = 0,9$; $\beta_2 = 0,999$; $\varepsilon = 10^{-8}$
Предобучение	100 эпох на каждый из четырёх автоэнкодеров
Выходной слой	30 supervised-эпох при фиксированных скрытых слоях
Совместное дообучение	До 400 эпох; $patience = 50$; минимум validation BCE
Режим вычислений	Полный batch, CPU, float32, один поток

В режиме без предобучения этап автоэнкодеров пропускается. Для изоляции его влияния оба режима получают одинаковую supervised-схему: 30 эпох только для выходного слоя, затем дообучение всей сети. В `baseline` скрытые слои на первом этапе случайны. Совпадают начальные веса, архитектура, оптимизатор, максимальный supervised-бюджет и правило выбора эпохи; фактическое число шагов может отличаться из-за `early stopping`.

$$Precision = TP / (TP + FP); \quad Recall = TP / (TP + FN)$$

$$F1 = 2TP / (2TP + FP + FN); \quad Accuracy = (TP + TN) / N$$

В матрицах ошибок строки — истинные классы, столбцы — предсказанные, порядок классов `[0, 1]`. Macro-F1 усредняет F1 двух классов. ROC-AUC рассчитывается по вероятностям, а не по бинарным предсказаниям, поэтому может отличаться при одинаковых матрицах ошибок.

4 Результаты послойного предобучения

Кривые и подробные матрицы далее показаны для заранее выбранного $\text{seed}=42$. Этот запуск не выбирался как лучший по тесту. Для каждого слоя предобучение останавливается после 100 эпох; приведены MSE перед первым шагом и после последнего шага.

Выборка	Автоэнкодер	MSE до	MSE после
Credit Approval	46–64–46	0,356780	0,041660
Credit Approval	64–32–64	0,325680	0,061902
Credit Approval	32–16–32	0,446011	0,045942
Credit Approval	16–8–16	0,578245	0,188742
WDBC	30–64–30	1,036022	0,116054
WDBC	64–32–64	0,555984	0,079317
WDBC	32–16–32	0,897913	0,196242
WDBC	16–8–16	0,873593	0,341176

Credit Approval; послойное предобучение, $\text{seed} = 42$




Рисунок 1 — Обучение четырёх автоэнкодеров Credit Approval

Для всех восьми автоэнкодеров в двух выборках MSE уменьшилась. Это подтверждает обучение восстановлению входного представления. Однако значения MSE разных слоёв относятся к разным размерностям и масштабам, поэтому непосредственно сравнивать их как качество классификации нельзя.

Код проверяет неизменность предыдущих слоёв при обучении текущего автоэнкодера и неизменность выходного слоя на этапе предобучения. После переноса весов первый supervised-этап обновляет только выходной слой; на этапе тонкой настройки изменяются все параметры сети.

5 Классификация Credit Approval




Рисунок 2 — Supervised-дообучение Credit Approval при seed 42

Минимальная validation BCE без предобучения равна 0,307900 на эпохе 102; с предобучением — 0,296726 на эпохе 132. Вертикальная линия отмечает выбранную эпоху. На оси X отсчитываются только эпохи совместного дообучения, без 30 эпох обучения выхода и без автоэнкодерных этапов.




Рисунок 3 — Матрицы ошибок Credit Approval на тесте при seed 42

В показанном запуске оба режима дали одинаковые матрицы ошибок: $TN = 70$, $FP = 7$, $FN = 6$, $TP = 55$. Accuracy = 90,58%, precision = 0,8871, recall = 0,9016, F1 = 0,8943. Это совпадение относится к порогу 0,5; веса и вероятности моделей различаются.

ROC-AUC без предобучения равна 0,955291, с предобучением — 0,957207. Для оценки зависимости результата от инициализации далее приведены все три запуска, включая seed 43 и 44.

6 Классификация WDBC




Рисунок 4 — Supervised-дообучение WDBC при seed 42

Минимальная validation BCE без предобучения равна 0,040014 на эпохе 155; с предобучением — 0,039937 на эпохе 99. Вертикальная линия отмечает выбранную эпоху. На оси X отсчитываются только эпохи совместного дообучения, без 30 эпох обучения выхода и без автоэнкодерных этапов.




Рисунок 5 — Матрицы ошибок WDBC на тесте при seed 42

В показанном запуске оба режима дали одинаковые матрицы ошибок: $TN = 72$, $FP = 0$, $FN = 2$, $TP = 40$. Accuracy = 98,25%, precision = 1,0000, recall = 0,9524, F1 = 0,9756. Это совпадение относится к порогу 0,5; веса и вероятности моделей различаются.

При этом совпадение матриц не означает совпадения решений для каждого объекта: при seed=42 предсказания различаются для двух тестовых объектов. Число ошибок каждого типа остаётся тем же. Для seed=43 и 44 совпадают и бинарные предсказания.

ROC-AUC без предобучения равна 0,980159, с предобучением — 0,996032. Для оценки зависимости результата от инициализации далее приведены все три запуска, включая seed 43 и 44.

7 Сравнение по трём инициализациям

Выборка	Seed	F1 без предобучения	F1 с предобучением	Разность F1
Credit Approval	42	0,8943	0,8943	0,0000
Credit Approval	43	0,9032	0,8571	-0,0461
Credit Approval	44	0,8960	0,8943	-0,0017
WDBC	42	0,9756	0,9756	0,0000
WDBC	43	0,9630	0,9630	0,0000
WDBC	44	0,9630	0,9630	0,0000

Среднее и выборочное стандартное отклонение по инициализациям
Credit Approval WDBC




Рисунок 6 — Средний F1 и его разброс по трём инициализациям

Выборка	Режим	Accuracy	F1	ROC-AUC
Credit Approval	Без предобучения	0,9082 ± 0,0042	0,8978 ± 0,0047	0,9485 ± 0,0139
Credit Approval	С предобучением	0,8961 ± 0,0167	0,8819 ± 0,0215	0,9400 ± 0,0306
WDBC	Без предобучения	0,9766 ± 0,0051	0,9672 ± 0,0073	0,9851 ± 0,0086
WDBC	С предобучением	0,9766 ± 0,0051	0,9672 ± 0,0073	0,9888 ± 0,0064

В таблице указаны среднее ± выборочное стандартное отклонение (ddof=1). Все запуски используют одну тестовую часть; меняются только начальные веса. Этот разброс характеризует чувствительность к инициализации, а не неопределённость по всем возможным разбиениям данных и не доверительный интервал.

Для Credit Approval средний F1 изменился с 0,8978 до 0,8819: разность -0,0159, или -1,59 процентного пункта при представлении F1 в процентах. Основное ухудшение наблюдается при seed=43: число FN увеличилось с 5 до 10. Для WDBC F1 совпал в каждой из трёх пар; среднее равно 0,9672.

8 Интерпретация результатов

Автоэнкодер оптимизирует восстановление входа, а классификатор — различение меток. Сохранение вариаций признаков не обязательно усиливает направления, важные для целевого класса. Поэтому снижение MSE на всех автоэнкодерных этапах совместимо с отсутствием улучшения F1. Полученные результаты не противоречат самому алгоритму предобучения.

Используемая baseline-сеть с ReLU и Adam уже обучается без предобучения. На WDBC она достигает высокого F1, поэтому дополнительная инициализация не изменила F1 и суммарную матрицу ошибок при пороге 0,5. Предобучение изменило ранжирование вероятностей: средний ROC-AUC увеличился с 0,9851 до 0,9888. Это наблюдение относится к данному фиксированному тесту.

Число эпох и вычислительные затраты

Выборка	Seed	Лучшая эпоха без предобучения	Лучшая эпоха с предобучением
Credit Approval	42	102	132
Credit Approval	43	113	118
Credit Approval	44	100	121
WDBC	42	155	99
WDBC	43	132	360
WDBC	44	146	157

Предобучение дополнительно требует $4 \times 100 = 400$ шагов по полным обучающим представлениям. Эти шаги имеют другую стоимость, чем шаг классификатора, поскольку автоэнкодеры различаются по размерности. Одинаковый максимум supervised-эпох не означает одинаковое полное время работы.

Для WDBC при seed=42 лучшая эпоха дообучения сместилась с 155 на 99, но при seed=43 — с 132 на 360. Следовательно, в проведённых запусках нельзя утверждать устойчивое ускорение. При seed=43 предобученная WDBC-сеть выполнила все 400 разрешённых эпох; сохранены веса эпохи 360. Ранний останов не срабатывает, если предел эпох достигнут раньше patience.

Границы выводов

Архитектура и параметры были зафиксированы до сравнения. Не проводился поиск лучших параметров по тесту. Три инициализации и одно разбиение дают ограниченный эксперимент: нельзя заключать, что предобучение всегда ухудшает Credit Approval или всегда бесполезно для WDBC. Для более широкого вывода потребовались бы дополнительные разбиения и оценка статистической устойчивости.

В отличие от лабораторной работы №2 здесь решается задача классификации. Нельзя переносить выводы о качестве реконструкции или разделении облаков на точность классификатора. Также используется новое стратифицированное разбиение и обучаемая только по train подготовка данных; числа из предыдущего отчёта напрямую не сопоставляются с текущими метриками.

9 Реализация и проверка программы

В файл встроена сжатая копия `src.data`; при загрузке проверяется SHA-256. WDBC берётся из `scikit-learn`. После установки зависимостей отдельные CSV и интернет для запуска не требуются. Для Credit Approval сохранены ссылка на UCI, автор, DOI и лицензия CC BY 4.0.

Команды запуска

```
python -m pip install numpy "scikit-learn>=1.2" matplotlib torch
python iad_lab3_variant1.py
python iad_lab3_variant1.py --no-show
python iad_lab3_variant1.py --self-test
```

Обычный запуск выполняет обе задачи и открывает семь рисунков `matplotlib`. Флаг `--no-show` сохраняет рисунки без окон. По умолчанию результаты помещаются в `results_lab3` рядом со скриптом; параметр `--out` меняет каталог. `--seeds`, `--pretrain-epochs` и `--epochs` позволяют менять условия эксперимента; отчёт соответствует значениям по умолчанию.

Сохраняются `results.json` с настройками, разбиением, кривыми и метриками; `metrics.csv`; CSV с вероятностями и предсказаниями каждого запуска; файлы весов `.pt` и обученные преобразователи `.joblib`. Для преобразования новых объектов следует использовать сохранённый преобразователь, а не обучать стандартизацию повторно.

Выполненные проверки

Проверены целостность встроенных данных, размеры выборок и численности классов, отсутствие пересечений `train/validation/test`, обучение стандартизатора только по `train`, конечность подготовленных признаков и наличие ровно пяти линейных слоёв классификатора.

Проверены уменьшение MSE после короткого предобучения, изменение кодирующих весов, неизменность предыдущих слоёв и выходной головы на соответствующих этапах, воспроизводимость при одинаковом `seed` и изменение скрытых весов при совместном дообучении. Также проверены диапазон вероятностей, сумма элементов матрицы ошибок и формулы `accuracy` и `F1`.

Режим `--self-test` прошёл. Полный запуск завершил все 12 экспериментов: две выборки, два режима и три инициализации. Таблицы и рисунки отчёта построены по результатам этого запуска. Детальные показатели дополнительных метрик и всех эпох доступны в JSON и CSV.

10 Выводы

Реализована сеть с пятью обучаемыми слоями и два режима её обучения для Credit Approval и WDBC. Автоэнкодерный режим выполнен по лекционному алгоритму: четыре последовательных этапа восстановления без меток, перенос кодирующих весов, supervised-обучение выхода и совместная тонкая настройка всех слоёв.

Данные разделены на независимые обучающую, валидационную и тестовую части. Подготовка и предобучение используют только train; лучшие веса выбираются по validation BCE. Сравнение проведено при одинаковых начальных весах внутри каждой пары и одинаковой supervised-схеме.

На Credit Approval средний F1 положительного класса составил 0,8978 без предобучения и 0,8819 с предобучением. Средний recall снизился с 0,9126 до 0,8798. Следовательно, в выполненном эксперименте baseline оказался предпочтительнее по F1.

На WDBC средний F1 равен 0,9672 в обоих режимах, средняя ассигаса — 97,66%. Различия ROC-AUC показывают, что совпадение F1 и матриц ошибок не означает совпадения всех предсказаний или вероятностных оценок. Предобучение не обеспечило устойчивого уменьшения числа эпох и добавило вычислительные затраты.

Основной вывод: автоэнкодерное предобучение является способом инициализации признаков слоёв, а не гарантией улучшения классификации. Его полезность следует проверять по целевым метрикам на отложенных данных. В данной конфигурации ReLU-сеть с Adam достаточно эффективно обучилась без него; вывод ограничен выбранными архитектурой, параметрами и разбиением.