

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №5
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных»
Тема: Деревья решений и ансамбли деревьев

Выполнил:
Студент 4 курса
Группы ИИ-26(2)
Семёнов А.В.
Проверил:
Никитин С.К.

Брест 2026

Классификация ирисов деревьями решений

1 Цель и исходные данные

Цель работы — сравнить одиночное дерево решений, случайный лес и три алгоритма бустинга на задаче определения вида ириса. По варианту 1 использован предоставленный файл iris.csv. Основная метрика — ассурасу на общей тестовой выборке. Дополнительно рассчитаны macro-F1, матрицы ошибок и точность кросс-валидации на обучающей части.

На выбранном тестовом разбиении наибольшую ассурасу 0,9778 получило дерево решений. Этот результат относится к 45 тестовым объектам и заданным параметрам; он не доказывает универсального превосходства метода.

Набор содержит 150 наблюдений, четыре числовых признака в сантиметрах и целевой столбец variety. Классы Setosa, Versicolor и Virginica представлены по 50 раз. Пропущенных, бесконечных и неположительных значений измерений не обнаружено. Идентификаторы строк не используются как признаки.

Признак	Минимум	Максимум	Среднее	Станд. откл.
Длина чашелистика	4,300	7,900	5,843	0,828
Ширина чашелистика	2,000	4,400	3,057	0,436
Длина лепестка	1,000	6,900	3,758	1,765
Ширина лепестка	0,100	2,500	1,199	0,762




Рисунок 1 — Исходные измерения ирисов и истинные виды

На проекции по размерам лепестков Setosa отделяется от двух других видов. Versicolor и Virginica частично перекрываются. Рисунок служит описанием данных; обучение и оценка всех моделей используют четыре признака. Средние и стандартные отклонения в таблице рассчитаны по всему CSV только для описания, а не для преобразования входов.

2 Методы и организация эксперимента

Одиночное дерево последовательно делит пространство по условиям вида $x_j \leq t$. Использован критерий Джини: чем меньше неоднородность классов в дочерних узлах, тем лучше разбиение. Ограничение глубины снижает сложность правил.

$$G = 1 - \sum_k p_k^2$$

Случайный лес обучает деревья на bootstrap-выборках и рассматривает случайные подмножества признаков при разбиениях. Итоговый класс выбирается по усреднённым вероятностям деревьев. Это уменьшает зависимость прогноза от одного дерева.

AdaBoost SAMME строит последовательность неглубоких деревьев и увеличивает веса ошибочно классифицированных объектов. Ответ определяется взвешенным голосованием. Использован вариант SAMME для трёх классов, а не двоичная формула AdaBoost.

CatBoost и XGBoost реализуют градиентный бустинг деревьев: ансамбль наращивается последовательно для уменьшения многоклассовой функции потерь. В программе используются их библиотечные классификаторы. Признаки Iris числовые, поэтому специальные возможности CatBoost для категорий здесь не задействованы.

Модель	Основные параметры
Дерево	criterion=gini; max_depth=3
Случайный лес	300 деревьев; max_features=sqrt; bootstrap=True
AdaBoost	SAMME; 200 деревьев глубины 1; learning_rate=0,5
CatBoost	300 итераций; depth=4; learning_rate=0,05; MultiClass
XGBoost	300 раундов; max_depth=3; learning_rate=0,05; multi:softprob; hist

Разбиение train/test выполнено один раз в соотношении 70/30 с random_state=42 и stratify=y. Получено 105 обучающих объектов (по 35 каждого вида) и 45 тестовых (по 15). Масштабирование и PCA не применяются: деревья сравнивают отдельные признаки с порогами. Все пять методов получают одни и те же строки и признаки.

Параметры выбраны заранее и не меняются после просмотра теста. На train проведена пятикратная StratifiedKFold с shuffle=True и random_state=42: в каждом фолде 84 объекта для обучения и 21 для проверки. Затем каждая модель заново обучена на всех 105 объектах и один раз оценена на test. Кросс-валидация не использована для подбора параметров.

Во всех случайных компонентах задан seed=42; лес, CatBoost и XGBoost используют один вычислительный поток. Число раундов не означает одинаковой вычислительной сложности: например, XGBoost при стандартном многоклассовом режиме строит по дереву для каждого класса за раунд.

3 Сравнение точности

$$Accuracy = N_{\text{правильных}} / N_{\text{тестовых}}$$

Основная оценка — доля правильных ответов из 45. Macro-F1 усредняет F1 трёх видов с равными весами. Train accuracy приведена для сопоставления с тестом, но не является оценкой обобщающей способности.

Модель	Train accuracy	Test accuracy	Верно / 45	Macro-F1
Дерево	0,9810	0,9778	44	0,9778
Случайный лес	1,0000	0,9111	41	0,9107
AdaBoost	1,0000	0,9333	42	0,9333
CatBoost	1,0000	0,8889	40	0,8878
XGBoost	1,0000	0,9333	42	0,9333




Рисунок 2 — Точность на тесте и при кросс-валидации train

Модель	CV accuracy $\pm$ SD	Ошибок на test	Обучение, с
Дерево	0,9524 $\pm$ 0,0476	1	0,0006
Случайный лес	0,9524 $\pm$ 0,0476	4	0,2414
AdaBoost	0,9333 $\pm$ 0,0426	3	0,2012
CatBoost	0,9619 $\pm$ 0,0398	5	0,0830
XGBoost	0,9524 $\pm$ 0,0337	3	0,0514

На графике показано выборочное стандартное отклонение пяти оценок CV (ddof=1), а не доверительный интервал. Время измерено для единственного финального fit без кросс-валидации, импорта и построения графиков; оно зависит от оборудования и не является строгим сравнением скорости библиотек.

Одна ошибка на тесте изменяет accuracy на $1/45 \approx 0,0222$, то есть на 2,22 процентного пункта. Поэтому малые различия на таком наборе следует трактовать осторожно. Результаты CV и test оцениваются на разных объектах и при разном объёме обучающей части.

4 Матрицы ошибок и разбор прогнозов




Рисунок 3 — Матрицы ошибок всех пяти классификаторов

Строки соответствуют истинным классам, столбцы — предсказанным. Обозначения: S — Setosa, Ve — Versicolor, Vi — Virginica. В каждой строке 15 объектов; сумма элементов каждой матрицы равна 45. Диагональные элементы — правильные ответы.

Деревья: Versicolor → Virginica: 1. Правильных ответов 44 из 45.

Случайный лес: Versicolor → Virginica: 1; Virginica → Versicolor: 3. Правильных ответов 41 из 45.

AdaBoost: Versicolor → Virginica: 1; Virginica → Versicolor: 2. Правильных ответов 42 из 45.

CatBoost: Versicolor → Virginica: 1; Virginica → Versicolor: 4. Правильных ответов 40 из 45.

XGBoost: Versicolor → Virginica: 1; Virginica → Versicolor: 2. Правильных ответов 42 из 45.

Полные precision, recall и F1 для каждого вида записываются в results.json. Файл predictions.csv содержит номер исходной строки CSV, истинный вид и ответы всех пяти моделей; заголовок CSV считается первой строкой. Это позволяет проверить каждую ошибку по исходным измерениям.

5 Интерпретация одиночного дерева




Рисунок 4 — Обученное дерево с ограничением глубины 3

Полученное дерево имеет глубину 3 и 5 листьев. В каждом узле указаны условие, неоднородность *gini*, число обучающих объектов *samples*, распределение *value* и выбранный класс. *value* может отображаться как доли классов в зависимости от версии *scikit-learn*; *samples* остаётся числом объектов. Левая ветвь соответствует выполнению условия, правая — его нарушению.

Признак	Важность по уменьшению Джини
Длина чашелистика	0,0000
Ширина чашелистика	0,0000
Длина лепестка	0,5509
Ширина лепестка	0,4491

Важности рассчитаны по обучающим разбиениям одного дерева и нормированы до суммы 1. Нулевая важность означает, что признак не был выбран данным деревом, а не отсутствие связи с видом ириса. Коррелирующие измерения могут заменять друг друга в правилах.

В отличие от ансамблей, дерево можно целиком проследить от корня к листу и объяснить отдельный прогноз через несколько порогов. Случайный лес и бустинг сочетают множество правил, поэтому для них одной компактной схемы недостаточно. Текстовое представление правил этого дерева сохраняется в `tree_rules.txt`.

6 Реализация и воспроизводимость

Вся программа находится в одном файле `iad_lab5_variant1.py`. В него встроена сжатая точная копия предоставленного `iris.csv` с проверкой SHA-256. Встроенный `sklearn.datasets.load_iris` не используется. Можно явно передать исходный файл через `--csv`; в этом случае проверяются структура, численность, классы и допустимость значений, а его SHA-256 записывается в результаты.

```
python -m pip install numpy scikit-learn matplotlib catboost xgboost
python iad_lab5_variant1.py
python iad_lab5_variant1.py --no-show
python iad_lab5_variant1.py --csv iris.csv --no-show
python iad_lab5_variant1.py --self-test
```

Обычный запуск выполняет 25 обучений внутри CV и пять финальных обучений, выводит метрики и открывает четыре графика. `--no-show` сохраняет графики без окон. Результаты помещаются в `results_lab5` рядом с программой; `--out` позволяет выбрать другой каталог.

Файл результата	Содержимое
<code>metrics.csv</code>	Сводные метрики, CV и время fit
<code>results.json</code>	Версии, SHA-256, индексы, метрики и матрицы
<code>predictions.csv</code>	Истинные виды и пять прогнозов на test
<code>tree_rules.txt</code>	Пороговые правила одиночного дерева
Четыре PNG	Данные, сравнение, ошибки, дерево

Самопроверка проверяет целостность встроенных данных, отсутствие пересечений индексов train/test, покрытие объектов фолдами CV, доли классов, размерность и нормировку вероятностей. Для всех пяти моделей выполнено повторное обучение с одинаковыми настройками и проверено совпадение прогнозов. Ассурасу сверена с долей диагональных элементов матрицы ошибок.

В исходном CSV обнаружено 1 повторное наблюдение по всем четырём признакам и классу. Данные сохранены как в задании. Число тестовых строк с точным совпадением четырёх признаков с train: 0. Разбиение выполнено по строкам; повторные измерения нужно учитывать при интерпретации, а не считать независимой проверкой на новой популяции.

7 Выводы

Выполнены все пункты варианта 1: загружен предоставленный Iris, изучены признаки и классы, выделены обучающая и тестовая части, обучены дерево, случайный лес, AdaBoost, CatBoost и XGBoost, рассчитана accuracy и проведено сравнение.

Наибольшая тестовая accuracy составила 0,9778 (44 правильных ответов из 45). Лучшей моделью по этой метрике стало дерево решений. На данном разбиении дерево оказалось точнее всех четырёх ансамблей.

По средней accuracy пятикратной кросс-валидации train наилучшее значение 0,9619 получено у CatBoost. Это дополнительное свидетельство в рамках фиксированного набора, а не основание объявлять статистически значимое превосходство. Настройки после сравнения не изменялись.

Для небольшого набора Iris простое дерево полезно своей наглядностью и небольшим числом правил. Лес снижает зависимость от одного дерева, но требует хранения ансамбля. AdaBoost, CatBoost и XGBoost дают альтернативные последовательные ансамбли; само увеличение числа моделей не гарантирует роста точности на каждом разбиении.

Вывод о лучшем методе ограничен одним тестом, заданными гиперпараметрами и небольшой выборкой. Для дальнейшего исследования уместны повторные стратифицированные разбиения и подбор параметров внутри вложенной кросс-валидации с сохранением внешнего теста. В данной работе такой подбор не выполнялся.