

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1

По дисциплине: «интеллектуальный анализ данных»
Тема: «РСА»

Выполнил:

Студент 4 курса
Группы ИИ-26
Заруцкий В.Я.

Проверил:

Никитин С. К.

Брест 2026

Цель работы: научиться применять метод PCA для осуществления визуализации данных.


Вариант 4:

4 | heart+failure+clinical+records.zip | death event



1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент (двумя способами: 1. вручную через использование `numpy.linalg.eig` для вычисления собственных значений и собственных векторов и 2. с помощью `sklearn.decomposition.PCA` для непосредственного применения метода PCA – два независимых варианта решения);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Используя собственные значения, рассчитанные на этапе 1, вычислить потери, связанные с преобразованием по методу PCA. Сделать выводы;

Ход работы

Проецирование двух компонент:



Проецирование трех компонент:



Размер датасета: (299, 13)

Первые строки:

	age	anaemia	creatinine_phosphokinase	diabetes	ejection_fraction	...	serum_sodium	sex
smoking	time	DEATH_EVENT						
0	75.0	0	582	0	20	...	130	1
0	4	1						
1	55.0	0	7861	0	38	...	136	1
0	6	1						
2	65.0	0	146	0	20	...	129	1
1	7	1						
3	50.0	1	111	0	20	...	137	1
0	7	1						
4	65.0	1	160	1	20	...	116	0
0	8	1						

[5 rows x 13 columns]

Пропущенные значения:

age	0
anaemia	0
creatinine_phosphokinase	0
diabetes	0
ejection_fraction	0
high_blood_pressure	0
platelets	0
serum_creatinine	0
serum_sodium	0
sex	0
smoking	0
time	0
DEATH_EVENT	0

dtype: int64

Признаки: ['age', 'anaemia', 'creatinine_phosphokinase', 'diabetes', 'ejection_fraction', 'high_blood_pressure', 'platelets', 'serum_creatinine', 'serum_sodium', 'sex', 'smoking', 'time']
Размер X: (299, 12)

Размер ковариационной матрицы: (12, 12)

Собственные значения (по убыванию):

```
[1.66854625 1.5843945 1.27239806 1.11968295 1.03333917 0.99219419
 0.88632232 0.84812523 0.76658155 0.71018618 0.64617272 0.51232534]
```

Доли объяснённой дисперсии (вручную):

```
[0.13858049 0.13159129 0.10567855 0.09299485 0.0858236 0.08240632
 0.07361317 0.07044072 0.06366814 0.05898425 0.05366763 0.04255099]
```

Доли объяснённой дисперсии (sklearn):

```
[0.13858049 0.13159129 0.10567855 0.09299485 0.0858236 0.08240632
 0.07361317 0.07044072 0.06366814 0.05898425 0.05366763 0.04255099]
```

Проверка совпадения (2 компоненты): True

=== Проекция на 2 главных компонент ===

Сохранённая дисперсия: 27.02%

Потерянная дисперсия: 72.98%

=== Проекция на 3 главных компонент ===

Сохранённая дисперсия: 37.59%

Потерянная дисперсия: 62.41%

=== Оценка по sklearn ===

2 компонент(ы): сохранено 27.02%, потеряно 72.98%

3 компонент(ы): сохранено 37.59%, потеряно 62.41%

Вывод по лабораторной работе: научился применять метод PCA для осуществления визуализации данных.