

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа № 2
За седьмой семестр
По дисциплине «Интеллектуальный анализ данных»
Тема: «Автоэнкодеры»

Выполнил:
Студент 4 курса
Группы ИИ-26
Черноиван А.Н.
Проверил:
Никитин С.К.

Цель: научиться применять автоэнкодеры для осуществления визуализации данных и их анализа

Общее задание

1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент с использованием нейросетевой модели автоэнкодера (с двумя и тремя нейронами в среднем слое);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Реализовать метод t-SNE для визуализации данных (использовать также 2 и 3 компонента), построить соответствующую визуализацию;
4. Применить к данным метод PCA (2 и 3 компонента), реализованный в ЛР №1, сделать выводы;
5. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Задание по вариантам









№	Выборка	Класс
8	Rice (Cammeo and Osmancik)	Class



Важные замечания

1. При реализации автоэнкодера архитектуру (количество слоев, нейронов, функции активации), а также параметры обучения подбирать экспериментально (рекомендовано начинать с более простых архитектур, использовать функции активации ReLU (особенно в случае глубоких НС), а также оптимизатор Adam);
2. Рекомендуется использовать вариант реализации метода t-SNE, включенный в пакет `sklearn` (`sklearn.manifold.TSNE`);
3. Для t-SNE рекомендуется выполнить визуализацию при различных значениях перплексивности (**perplexity**) и отобрать наиболее презентативную (рекомендуется выбирать значение данного параметра из диапазона от 20 до 60);
4. Для начальной инициализации t-SNE можно использовать метод PCA (опция **init**).

Результаты:

```
/Users/anastasiacernoivan/Documents/иад/lab1/.venv/bin/python /Users/
Объектов: 3810, признаков: 7, классы: ['Cammeo', 'Osmancik']
AE (2 нейрона), эпоха 1: MSE = 0.98956
AE (2 нейрона), эпоха 50: MSE = 0.10835
AE (2 нейрона), эпоха 100: MSE = 0.08600
AE (2 нейрона), эпоха 150: MSE = 0.07959
AE (3 нейрона), эпоха 1: MSE = 1.00006
AE (3 нейрона), эпоха 50: MSE = 0.00231
AE (3 нейрона), эпоха 100: MSE = 0.00171
AE (3 нейрона), эпоха 150: MSE = 0.00154
Итоговая MSE автоэнкодера: 2 нейрона = 0.07907, 3 нейрона = 0.00151
Потери PCA: 2 компоненты = 13.16%, 3 компоненты = 0.29%
```





Вывод: данные Rice практически трёхмерны: PCA теряет 13.16% информации на 2 компонентах и лишь 0.29% на 3, что согласуется с автоэнкодером (MSE 0.079 для 2 нейронов и 0.0015 для 3), поэтому переход к 3D заметно улучшает представление. Автоэнкодер восстанавливает данные точнее линейного PCA, но его 2D-проекция получается изогнутой и сильно скученной, а классы перекрываются, тогда как в PCA они хорошо разделяются вдоль первой компоненты с небольшой зоной перекрытия. t-SNE (perplexity = 30) даёт наиболее чёткое разделение: Cammeo образует компактную область справа, Osmancik распадается на несколько кластеров слева, а перекрытие остаётся только на границе; при perplexity 40–60 структура заметно не меняется, лишь становится более сглаженной.